

Dokumentacja - Projekt Big Data

Składowanie danych w systemach Big Data

Kamień milowy 1

Autorzy:

Jan Cwalina, Mikołaj Guzik

Wydział Matematyki i Nauk Informacyjnych
Politechnika Warszawska
15 stycznia 2026

Spis treści

1	Cel projektu	2
2	Uzasadnienie biznesowe	2
3	Źródła danych	2
3.1	Opis danych	3
4	Architektura	4
4.1	Plan pozyskiwania danych	5
4.2	Technologie	5
4.3	Przepływ danych	6
4.4	Diagram architektury	7
4.5	Struktura katalogów projektu	7
4.5.1	Lokalny system plików maszyny wirtualnej	7
4.5.2	Rozproszony system plików HDFS (docelowe miejsce przechowywania danych)	8
4.5.3	Struktura w Apache HBase	8

1 Cel projektu

Celem projektu jest stworzenie procesu przetwarzania i analizy danych dla dwóch miast: Londynu i Nowego Jorku. Projekt zakłada pozyskanie oraz integrację danych z trzech niezależnych źródeł: platformy **Inside Airbnb** oraz serwisów **data.police.uk** i **NYC Open Data**.

Głównym założeniem jest zbudowanie środowiska typu Big Data, które umożliwi gromadzenie, przetwarzanie i wizualizację danych z wykorzystaniem narzędzi takich jak Apache NiFi, Hadoop, Hive i Spark. W efekcie system pozwoli badać zależności pomiędzy aktywnością wynajmu krótkoterminowego a poziomem przestępczości w poszczególnych dzielnicach wybranych miast.

Projekt ma charakter analityczny i może stanowić podstawę dla decyzji podejmowanych przez administrację miejską, inwestorów lub platformy turystyczne. Analiza pozwoli zidentyfikować obszary, w których wysoka intensywność wynajmu pokrywa się z większą liczbą zgłoszonych przestępstw, co może być wykorzystane do oceny wpływu turystyki i krótkoterminowego wynajmu na bezpieczeństwo publiczne. Dodatkowo, zbudowana architektura przetwarzania danych może być rozwijana w kierunku cyklicznego monitorowania trendów miejskich w czasie rzeczywistym.

2 Uzasadnienie biznesowe

Projekt ma charakter analityczny i może być wykorzystany przez różne grupy interesariuszy, dla których istotne jest zrozumienie zależności pomiędzy intensywnością wynajmu krótkoterminowego a poziomem bezpieczeństwa publicznego.

- **Władze miejskie i samorządy lokalne** – mogą wykorzystać wyniki analizy do lepszego planowania polityki mieszkaniowej, turystycznej i bezpieczeństwa. Dane pozwolą identyfikować obszary o dużej koncentracji wynajmów Airbnb oraz zwiększonym ryzyku występowania przestępstw.
- **Służby porządkowe i policja** – analiza przestrzenna może pomóc w efektywniejszym rozmieszczaniu patroli i alokacji zasobów w dzielnicach, gdzie obserwowany jest wzrost aktywności turystycznej i przestępczości.
- **Firmy i inwestorzy z sektora nieruchomości** – uzyskane dane mogą wspierać decyzje dotyczące inwestycji w wynajem krótkoterminowy lub długoterminowy, uwzględniając poziom bezpieczeństwa w danym obszarze.
- **Platformy turystyczne i właściciele nieruchomości** – mogą analizować, jak bezpieczeństwo wpływa na liczbę rezerwacji i ceny wynajmu w poszczególnych dzielnicach.

W ujęciu szerszym projekt ma także znaczenie edukacyjne i badawcze. Integracja otwartych danych publicznych z różnych źródeł pozwala zrozumieć, jak technologie Big Data mogą wspierać analizy miejskie, zarządzanie przestrzenią i rozwój miast.

3 Źródła danych

Inside Airbnb

- **Adres:** <https://insideairbnb.com/get-the-data/>
- **Zakres:** dane o ofertach wynajmu w Londynie (snapshot z 10 czerwca 2025) i Nowego Jorku (snapshot z 1 listopada 2025)
- **Format:** CSV (**listings**) + GeoJSON (**neighbourhoods**)
- **Główne atrybuty:** latitude, longitude, price, neighbourhood, room_type, number_of_reviews, itp.
- **Częstotliwość aktualizacji:** co 3–4 miesiące (dane publikowane w formie snapshotów obejmujących stan na konkretny dzień)
- **Cel użycia:** analiza rozmieszczenia ofert Airbnb i porównanie z poziomem przestępczości

data.police.uk

- **Adres:** <https://data.police.uk/data/>
- **Zakres:** dane o przestępczości Londynie z czerwca 2025
Wybrane jednostki: Metropolitan Police Service (Greater London)
- **Format:** CSV
- **Główne atrybuty:** Crime type, Month, Latitude, Longitude, Location, LSOA name
- **Częstotliwość aktualizacji:** co miesiąc, z opóźnieniem około 2 miesięcy względem dzisiejszej daty
- **Cel użycia:** analiza rozmieszczenia i rodzaju przestępstw w tych samych obszarach co oferty Airbnb

NYC Open Data

- **Adres:** <https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date->
- **Zakres:** dane o przestępczości aresztowaniach w NYC w 2025 roku.
- **Format:** CSV/JSON
- **Główne atrybuty:** ARREST_DATE, PD_DESC, Latitude, Longitude, Location, PREP_SEX, PREP_RACE
- **Częstotliwość aktualizacji:** co dzień
- **Cel użycia:** analiza rozmieszczenia i rodzaju przestępstw w tych samych obszarach co oferty Airbnb

3.1 Opis danych

Inside Airbnb

Zbiory `listings.csv` zawierają dane opisujące wszystkie aktywne oferty wynajmu w serwisie Airbnb dla miast Londyn i Nowego Jorku. Każdy wiersz odpowiada jednej ofercie wynajmu.

- **Liczba rekordów:** około 96 tys. (Londyn)
- **Liczba kolumn:** 79
- **Najważniejsze atrybuty:**
 - `id` – unikalny identyfikator oferty,
 - `name` – nazwa oferty,
 - `host_id`, `host_name` – dane identyfikujące gospodarza,
 - `neighbourhood`, `neighbourhood_cleansed` – nazwa dzielnicy lub obszaru,
 - `latitude`, `longitude` – współrzędne geograficzne oferty,
 - `room_type` – typ zakwaterowania (np. Entire home/apt, Private room),
 - `price` – cena za noc (GBP),
 - `number_of_reviews` – liczba opinii użytkowników,
 - `availability_eoy` – liczba dni, w których oferta była dostępna w ciągu roku.
- **Plik GeoJSON:** `neighbourhoods.geojson` – zawiera granice administracyjne dzielnic obu miast wykorzystywane do agregacji i wizualizacji przestrzennej.

data.police.uk

Zbiory danych z portalu `data.police.uk` zawierają informacje o przestępstwach zgłoszonych w czerwcu 2025 roku na obszarze działania dwóch jednostek policyjnych: Metropolitan Police Service (Greater London) oraz Avon and Somerset Constabulary.

Każdy wiersz w pliku CSV reprezentuje jedno zdarzenie kryminalne z przypisaną kategorią i lokalizacją.

- **Liczba rekordów:** około 100 tys. (Londyn)
- **Liczba kolumn:** 12
- **Najważniejsze atrybuty:**
 - `Crime ID` – identyfikator zdarzenia,
 - `Month` – miesiąc zgłoszenia,
 - `Reported by` – jednostka policyjna rejestrująca zdarzenie,
 - `Crime type` – kategoria przestępstwa (np. burglary, robbery, vehicle crime),
 - `Last outcome category` – wynik postępowania (np. investigation complete, no suspect identified),
 - `Latitude`, `Longitude` – przybliżone współrzędne miejsca zdarzenia,
 - `Location` – opis lokalizacji (np. Near High Street),
 - `LSOA name` – jednostka statystyczna (Lower Layer Super Output Area).

NYC Open Data

Zbiory danych z portalu `data.police.uk` zawierają informacje o aresztowaniach dokonanych w roku 2025.

Każdy wiersz w pliku CSV reprezentuje jedno aresztowanie z przypisaną kategorią i lokalizacją.

- **Liczba rekordów:** około 212 tys.
- **Liczba kolumn:** 19
- **Najważniejsze atrybuty:**
 - `ARREST_KEY` – identyfikator zdarzenia,
 - `ARREST_DATE` – dokładna data aresztowania,
 - `PD_DESC` – opis klasy zdarzenia,
 - `OFNS_CODE` – opis klasyfikacji wewnętrznej odpowiadający kodowi KY (bardziej ogólny niż PD),
 - `ARREST_BORO` – obszar zdarzenia (B(Bronx), S(Staten Island), K(Brooklyn), M(Manhattan), Q(Queens)),
 - `Latitude`, `Longitude` – przybliżone współrzędne miejsca zdarzenia,
 - `Location` – opis lokalizacji (np. Near High Street),
 - `PERPRACE~rasaaresztowanego`.

4 Architektura

Celem architektury jest zbudowanie hybrydowego pipeline’u przetwarzania danych, łączącego przetwarzanie wsadowe (*batch*) z symulowanym strumieniowym (*streaming*), który integruje dane z trzech niezależnych źródeł (Inside Airbnb, data.police.uk oraz NYC Open Data) i przygotowuje je do analiz przestrzennych dla Londynu oraz porównań z Nowym Jorkiem. Ze względu na zakres projektu stosujemy rozwiązanie jedno-węzłowe (lokalne), zachowując koncepcję typowej architektury Big Data (warstwy danych, rozdział ingestu, składowania i przetwarzania).

4.1 Plan pozyskiwania danych

W projekcie przyjęto hybrydowy model pozyskiwania danych, obejmujący dane z grudnia 2025 roku. Celem jest analiza porównawcza rozmieszczenia ofert wynajmu krótkoterminowego oraz aktywności przestępczej w tym samym okresie dla Londynu z odniesieniem do aktywności policyjnej w Nowym Jorku. Dane policyjne będą symulowane jako strumieniowe na podstawie dat zgłoszeń.

Dane planuje się pobrać z trzech niezależnych źródeł publicznych:

- z serwisu Inside Airbnb, który udostępnia szczegółowe informacje o ofertach wynajmu krótkoterminowego. Dla obu miast zostaną wykorzystane pliki `listings.csv` oraz `neighbourhoods.geojson` w wersji z 6 grudnia 2025 roku, zawierające dane o lokalizacji, cenie, typie zakwaterowania i liczbie recenzji, itp.,
- z portalu `data.police.uk`, który publikuje dane o przestępczości na poziomie ulicy. Dla Londynu zostanie użyta jednostka Metropolitan Police Service. Planowane jest pobranie danych z grudnia 2025 roku w formacie CSV (pliki ZIP rozpakowane do lokalnego katalogu projektu),
- z serwisu NYC Open Data, udostępniającego dane o aktywności policyjnej poprzez API Socrata (endpoint: `https://data.cityofnewyork.us/resource/uip8-fykc.json`). Dane będą pobierane w formacie JSON i konwertowane do formatu Avro, obejmując aresztowania z grudnia 2025 roku, z kolumnami takimi jak `data`, `aresztowania`, `opis przestępstwa` i `lokalizacja`.

Dane z Inside Airbnb zostaną zapisane bezpośrednio w HDFS w warstwie `raw` `data`. Dane policyjne (z `data.police.uk` i NYC) będą symulowane jako strumieniowe poprzez Apache NiFi, który odczytuje dane z plików lokalnych i kieruje je do Apache Kafka w oparciu o daty zgłoszeń. Na tym etapie nie przewiduje się cyklicznego odświeżania danych, ponieważ celem projektu jest jednorazowa analiza przekrojowa z symulacją strumienia.

W ramach weryfikacji poprawności planowane jest sprawdzenie plików pod kątem zgodności formatu (rozszerzenia `.csv`, `.geojson`, `.json`) oraz liczby rekordów większej od zera. W przypadku wykrycia błędów (np. pustych archiwów ZIP lub nieudanych zapytań API) pliki będą wykluczane z dalszego przetwarzania.

Celem etapu jest przygotowanie kompletnych i poprawnych danych źródłowych, które posłużą do dalszych etapów przetwarzania i analizy w środowisku Big Data.

4.2 Technologie

- **Apache NiFi (ingest)** – automatyzuje proces ingestu danych: pobiera dane Airbnb (CSV, GeoJSON) oraz dane policyjne (CSV z `data.police.uk`, przetworzony Avro z NYC Open Data), wykonuje walidację i normalizację formatów, a następnie kieruje dane batchowe (Airbnb) bezpośrednio do HDFS oraz symuluje strumieniowe przetwarzanie danych policyjnych poprzez routing do Apache Kafka.
- **Apache Kafka (streaming broker)** – pełni rolę brokera komunikatów dla symulowanego strumienia danych policyjnych (topic: `police-stream`), umożliwiając asynchroniczne przetwarzanie zdarzeń w czasie rzeczywistym. Kafka odbiera dane z NiFi i dostarcza je do Apache Spark Structured Streaming.
- **HDFS / Hadoop (batch storage)** – stanowi główne repozytorium dla danych batchowych, z uporządkowaną strukturą katalogów `data/` podzieloną na poziomy: `raw` (dane w oryginalnej formie z Airbnb), `processed` (po wstępnym przetworzeniu i czyszczeniu) oraz `analytical` (gotowe do analiz). Dane są składowane w formacie Parquet dla efektywności przetwarzania.
- **Apache HBase (NoSQL storage)** – przechowuje ujednolicone dane policyjne pochodzące ze strumienia Kafka. HBase pozwala na szybki dostęp do danych o przestępczości według klucza (`data` + `geohash`) i elastyczne dodawanie kolumn dla różnych źródeł (UK i NYC), pomimo różnic w schematach danych źródłowych.
- **Apache Spark (unified processing engine)** – odpowiada za całościowe przetwarzanie danych: *Spark Streaming* konsumuje dane policyjne z Kafka, ujednolica różne schematy (UK vs NYC) i zapisuje do HBase; *Spark Batch* przetwarza dane Airbnb z HDFS, wykonuje czyszczenie, joiny przestrzenne (z danymi policyjnymi z HBase), agregacje na poziomie dzielnic/LSOA i zapisuje wyniki do HDFS w warstwie `processed` i `analytical`.

- **Apache Hive (SQL interface)** – udostępnia warstwę SQL nad danymi składowanymi w HDFS, umożliwiając tworzenie zewnętrznych tabel nad danymi w Parquet oraz integrację z danymi w HBase poprzez Hive-HBase connector. Pozwala na wykonywanie zapytań analitycznych SQL i łatwe połączenie z narzędziami Business Intelligence do raportowania.
- **Warstwa wizualizacji** – notebook (Python) lub narzędzie BI umożliwia tworzenie map oraz wykresów porównawczych pokazujących kluczowe zależności w danych, w tym porównania z NYC.

4.3 Przepływ danych

1. Ingest (*NiFi*):

- Dane Airbnb: pobranie plików `listings.csv` i `neighbourhoods.geojson`, walidacja i bezpośredni zapis do HDFS w warstwie *raw*.
- Dane policyjne NYC: pobranie JSON via API Socrata, konwersja do formatu Avro poprzez procesor QueryRecord.
- Dane policyjne UK: odczyt z lokalnych plików CSV (rozpakowane ZIP z `data.police.uk`).
- Symulacja strumienia: routing danych policyjnych (NYC i UK) do Kafka topic `police-stream` w oparciu o daty zgłoszeń.

2. Przetwarzanie strumieniowe (*Spark Streaming + HBase*):

- Spark Structured Streaming konsumuje dane z Kafka topic `police-stream`.
- Ujednolicenie schematów: transformacja różnych kolumn z UK i NYC do wspólnego formatu.
- Czyszczenie i walidacja: filtrowanie nieprawidłowych współrzędnych, standaryzacja typów przestępstw.
- Zapis do HBase: dane policyjne zapisywane z kluczem złożonym (`data + geohash`) dla szybkiego dostępu przestrzennego.

3. Przetwarzanie batchowe (*Spark Batch*):

- Odczyt danych Airbnb z HDFS warstwy *raw*.
- Czyszczenie: usunięcie duplikatów, parsowanie cen, standaryzacja nazw dzielnic/LSOA, kontrola zakresów `lat/lon`.
- Odczyt danych policyjnych z HBase.
- Joiny przestrzenne: przypisanie ofert Airbnb i przestępstw do poligonów (`neighbourhoods/LSOA`) lub siatki geohash.
- Zapis danych przetworzonych do HDFS w warstwie *processed* (format Parquet).


4. Agregacje i analityka (*Spark*):

- Obliczanie metryk per dzielnica: liczba ofert, mediana ceny, liczba przestępstw, wskaźniki bezpieczeństwa.
- Porównania międzymiastowe (London vs NYC).
- Zapis wyników do HDFS w warstwie *analytical* (format Parquet).

5. Zapytania SQL i raportowanie (*Hive*):

- Utworzenie zewnętrznych tabel Hive nad danymi w HDFS (*processed, analytical*).
- Integracja Hive-HBase dla dostępu SQL do danych policyjnych.
- Wykonywanie zapytań analitycznych i eksport wyników do wizualizacji.

4.4 Diagram architektury



4.5 Struktura katalogów projektu

Ze względu na jednowęzłowy charakter środowiska oraz konieczność zapewnienia powtarzalności, bezpieczeństwa danych i łatwości współpracy zdalnej, przyjęto ścisły podział katalogów zarówno w lokalnym systemie plików maszyny wirtualnej, jak i w rozproszonym systemie plików HDFS oraz bazie HBase.

4.5.1 Lokalny system plików maszyny wirtualnej

Wszystkie duże pliki danych są świadomie wyłączone z repozytorium Git (poprzez wpis w pliku `.gitignore`), dzięki czemu repozytorium pozostaje lekkie, a partner może je sklonować bez problemów.

```
/home/<user>/bigdata-project/
data/                          # ← cały folder w .gitignore
  raw/                         # tylko do ręcznych testów / backupu
  temp/                        # tymczasowe pliki NiFi (automatycznie czyszczone)
scripts/                       # skrypty pomocnicze
  download_airbnb.sh
  download_police_uk.py
  download_nyc_api.py
nifi-templates/               # eksportowane szablony flow
spark-jobs/                   # .py lub .scala z zadaniami Spark
hive-sql/                     # pliki .hql
notebooks/                    # Jupyter / Zeppelin
docs/                          # dokumentacja projektu
README.md, environment.yml, ...
```

Uwaga: w docelowym rozwiązaniu folder `data/raw/` nie jest używany w codziennej pracy – wszystkie surowe pliki trafiają bezpośrednio do HDFS.

4.5.2 Rozproszony system plików HDFS (docelowe miejsce przechowywania danych)

Wszystkie surowe i przetworzone zbiory danych przechowywane są wyłącznie w HDFS, co zapewnia replikację, bezpieczeństwo i najwydajniejszy dostęp dla Spark i Hive.

```
hdfs dfs -ls -R /user/<user>/bigdata
```

```
/user/<user>/bigdata/  
raw/  
  airbnb/  
  police/  
    police_nyc/  
    police_uk/  
processed/  
  airbnb/  
  police/  
    police_nyc/  
    police_uk/  
analytical/  
dimensions/
```

Katalogi tworzone są raz na początku projektu poleceniem:

```
hdfs dfs -mkdir -p /user/$USER/bigdata/{raw/{airbnb/,  
  \police_uk/,police_nyc},processed/{airbnb_clean,police_events,geo},\  
analytical/{agg_neighbourhood,agg_geohash,reports}}  
hdfs dfs -chmod -R 755 /user/$USER/bigdata
```

4.5.3 Struktura w Apache HBase

Namespace: bigdata

Tabela: bigdata:police_events

Column families:

```
cf_common : pola wspólne dla UK i NYC (crime_type, latitude, longitude, timestamp)  
cf_uk      : pola specyficzne dla data.police.uk (lsoa_code, reported_by, falls_within, ...)  
cf_nyc     : pola specyficzne dla NYC Open Data (pd_desc, law_cat_cd, arrest_boro, ...)
```

Przykładowy rowkey:

```
202512_<geohash7>_<uuid>
```

Dzięki tak zdefiniowanej strukturze:

- wszystkie surowe pliki trafiają bezpośrednio z NiFi do HDFS (brak duplikacji na dysku VM),
- Spark i Hive mają natychmiastowy dostęp do danych bez dodatkowych kopii,
- łatwo skalować projekt w przyszłości na klaster wielowęzłowy,
- partner pracujący zdalnie widzi dokładnie tę samą strukturę po uruchomieniu środowiska lokalnego.